2016 Machine Learning

Final Project Report

**Transfer Learning on Stack Exchange Tags**

**★Team**：NTU_b02901001_好多好多柳丁腳踏車

**★Members**：

b02901001 鍾勝隆, b02901014 王崇勳,b02901018 莊馥宇,b02901071 黃淞楓

**★Work Division**:

鍾勝隆：model dicussing、sub sub coder、writing report

王崇勳：model dicussing、sub coder、writing report

莊馥宇：model dicussing、main coder、writing report

黃淞楓：Github maintenance、running experiments、writing report

**★Problem Description**：

針對在物理論壇的提問文章，根據文章標題與內容，預測出其屬於的領域或相關主題(tag)，最後再計算預測的準確性。

**★Preprocess**：

首先，要先對所有資料作前處理。在 content 的部分都會出現 HTML 的 tag，例如：<p>或是<\p>；另外，因爲主題是**物理相關**文章，會出現以 **LaTeX** 格式編輯的數學公式，其中的數學符號會是大量且頻繁出現的資訊，在我們的模型之中，這些資訊並不會被使用到，反而還可能會誤認其爲正確的 tag，故得先將他們過濾掉（之後的實驗主要是以其他主題的文章，這點的影響就比較小）。

1. Removing HTML Tags:

(1) Motivation

觀察最原始的文件檔案，可以看到 content 之中充滿了 HTML 的 tag，明顯對於我們建立模型與判斷標籤有不利的影響，必須將它們去除，以得到乾淨的內容。

(2) Implementation

使用 beautifulsoup4，一個專門在網路上爬蟲的套件，根據 html tag 將文章進行 DOM tree 結構的切割，將完整的內文取出，然後把所有的內文相接，刪除所有相關的 html tag，成功把 HTML tag 去除。

2. Removing Math Symbol and Notation:

(1) Motivation

經過上述 Beautifulsoup 處理過的標題與資料，仍然有許多對於後來模型判斷不利之處。例如在 title 與 content 之中，常常會遇到換行符號”\n”，且很多句子中都包含數學表示式，其中的標籤與數學符號都會對模型造成不利的影響，必須清除乾淨。

(2) Implementation

我們首先將原本以換行符號”\n”連結的句子切開，得到多個句子。所有在"**$**"、“**$$**”、“**\\begin{equation}**”或“**\\begin{align}**”，與"**$**"、“**$$**”、“**\\end{equation}**”或“**\\end{align}**”之間的內容都會被拔除，藉此將所有以這類方式表示的數學符號都刪掉。然而，經過這樣處理後的內文仍然會存在一些夾雜於文字間的數學符號，這部分我們並沒有多做處理。

我們將上述方法實作於 preprocess.py 的檔案中。對於整篇文章中的標題和內文都進行上述的步驟，完成前處理。

**★Model：**

Model 可以分成兩部分，生成 **bigram 字典**和**產生 feature** 兩部分。

**※第一部分:**

1. Bigram generation

(1.)Motivation

在 physics 的文章中，含有片語的 tag，在標準的格式上要用“**-**”連接，如 quantum-mechanics，因此我們嘗試先將文章中的片語取出，做為未來預測 tag 的依據。

(2.) Implementation

使用 sklearn 中的 countvectorizer 取文件檔案中的 bigram，透過設定 ngram_range=(2, 2)，建立出一個 bigram 字典，並取出出現次數**前 600 個 bigram features**，作爲潛在的 tag。

2. Abbreviation replacement

(1.)Moivation

觀察模型的輸出可以發現，某些較長的詞彙有可能會以簡稱的方式出現，例如：quant field theory 變成 qft。然而正確的 tag 並不會以簡寫方式出現，因此我們必須將這些寫替換成原本的單字(片語)。

(2.) Implementation

我們所建出 bigram 字典中的詞彙，建立一個**簡稱與 bigram 間互相對應的字典**，法是對於每一個詞，我們都取組成這個詞的每一個單字的第一個字母，組合成一個簡寫，並建一個 python 的 dictionary 紀錄"簡寫-詞"的對應關係。

最後回頭掃過整份文件的 title 與 content，找尋屬於潛在詞彙(bigram)的字，透過一次詞句轉換兩個字之間加上“-”；同時在遇到簡稱時將其換掉。

**※第二部分(擇一作爲一個 model):**

a. 將 title 和 content 視爲一篇文章，並使用 sklearn 中的 countvectorizer 計算 **term frequency(tf)**以篩選重要的與 bigram 字句，進而將其選出當作是 tag。設定 min_df=100，代表出現次數少於 100 的字便不將其視爲 tag；而設定 max_df=0.3 代表只要出現次數超過整體字數的三成，便視爲不重要的字，也不會當成 tag。

b. 將 title 和 content 視爲一篇文章，使用 sklearn 中的 tfidfvectorizer 計算 **term frequency(tf)** 以及 **inverse document frequency(idf)**以篩選重要的字句，進而將其選出當作是 tag。

c. 由於要找出的 tag 幾乎大部分的 tag 都是名詞，因此在使用 bigram 之後，使用 ntlk 中的 **Pos_tag** 濾出屬於**名詞**的字（'NN'、'NNP'、'NNS'、'NNPS'），處理好後再套用到(a)中的 model。

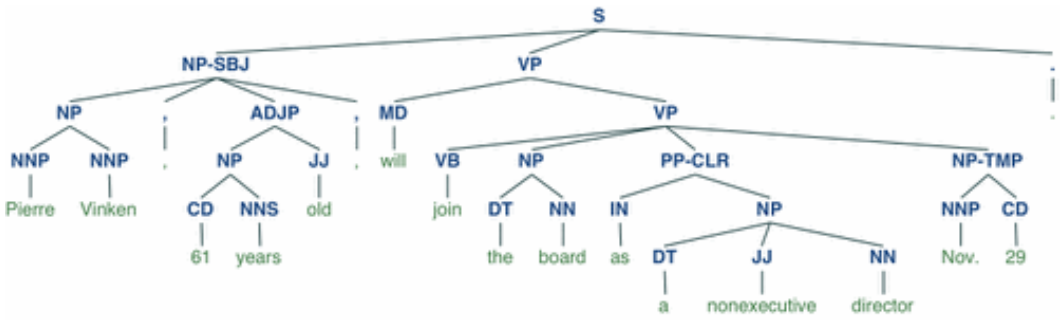


(圖一) POS_tag 的分類與例子

d. 將(b)中的模型加上 **POS_tag**，與(c)同理。

綜合 preprocess 以及 model 的部分，我們可以得到一個流程圖，如圖(二)。

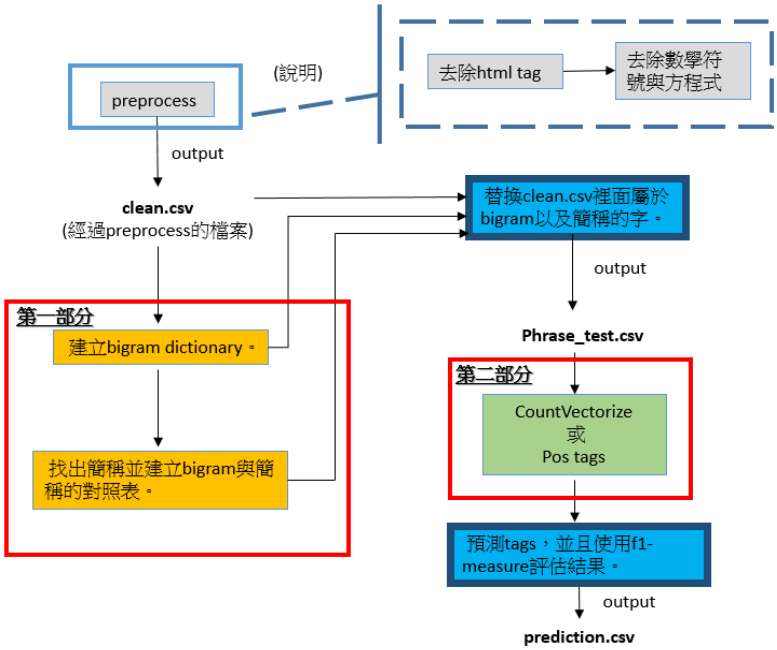


（圖二）Model 流程圖

**★Experiments and Discussion：**

**※Physics (Kaggle)**

我們在 Kaggle 上的繳交紀錄主要可以分成四個階段，每個階段在模型中加入了一些新的功能，因此有較大的進步；其他模型上的微調則影響較小，我們在以下的表格中，皆只取每個階段中微調後的最好結果進行呈現。

1. 加入 Bigram

我們在一開始處理這個題目時，單純使用 sklearn 內建的 tfidf，計算每一個單詞的分數，並且取前三名作為每筆測試資料的輸出。然而，這個方法完全忽略了片語的存在，因此表現不佳。因此我們在之後使用 tfidf 同時計算 monogram 與 bigram，並且取前三名作為輸出，結果如下：

| | Without bigram | With naive bigram |
|---|---|---|
| Kaggle public (best) | 0.06455 | 0.08118 |

可以看到加入 bigram 後，表現有明顯提升，已經超過 weak baseline。

2. 在文件中連接片語

前一階段的方法雖然可以提升效果，但並不理想。不理想的原因主要在於 tfidf 計算 monogram 和 bigram 時會有一些冗餘的情形發生。舉例來說，在上面的方法我們會同時預測出 quantum、quantum-mechanics、mechanics 三個詞，但實際上只有片語，也就是 bigram 才是正確的 tag。因此我們在這個階段，先計算出前 600 名常出現的 bigram，在原始文件中連接後，再進行 tfidf 計算 monogram。結果如下：

| | With naive bigram | Connect bigram in document |
|---|---|---|
| Kaggle public (best) | 0.08118 | 0.09184 |

可以看到我們事先在文件中處理 bigram 的問題後，得到大約 1%的效果提升。

3. 使用 POS tag 刪除非名詞

在前一階段中，我們模型預測出的 tag 包含了一些形容詞與動詞，但通常這些詞並不會是正確 tag 的一部分，因此必須將它們刪除。結果如下：

| | Without POS tag | With POS tag |
|---|---|---|
| Kaggle public (best) | 0.09184 | 0.11999 |

可以看到這個階段的進步超過 2%，進步幅度相當顯著。

4. 將 content 所有 bigram 加入 tag 中

在這個階段，我們認為所有在資料中出現的 bigram 都與資料的主題極度相關，因此我們將一筆資料中所有出現的 bigram 都加入預測 tag 中。結果如下：

| | Without adding all bigram | Adding all bigram |
|---|---|---|
| Kaggle public (best) | 0.11999 | 0.12978 |

結果進步約 1%左右。

**※Other topics**

1. Model performance

要測試設計出的 model，我們嘗試用不同領域的文章當做輸入，預測出該領域中每篇文章對應的 tag，觀察使用不同 model 的表現下，預測的結果如何。我們使用的文章爲 biology.csv, cooking.csv, crypto.csv, diy.csv, robotic.csv, travel.csv，這六個領域的文章集合。因為每個文章都有提供正確的 tag，方便計算其分數，以評估 model 的好壞。

每個 model 針對**不同種類**文章的的 F1-measure 分數：
(分數計算方式爲**各個 id 的 F1 score 以其 tag 個數做加權平均**)

| category | Model A | Model B | Model C | Model D |
|---|---|---|---|---|
| biology | 0.04901 | 0.05078 | 0.08600 | 0.08601 |
| cooking | 0.12958 | 0.13246 | 0.27373 | 0.27247 |
| crypto | 0.07165 | 0.07464 | 0.13869 | 0.13838 |
| diy | 0.10604 | 0.10868 | 0.18915 | 0.18901 |
| robotics | 0.09944 | 0.10019 | 0.17358 | 0.17402 |
| travel | 0.08002 | 0.08643 | 0.15031 | 0.15000 |

經過實驗可以發現 Model C 和 Model D 的效能表現**沒有特別的差異**，但 Model C 平均都比 Model D 的 accuracy 些微高一點，我們判斷可能是 tfidfvectorizer 中有考慮到 idf 這個參數，透過考慮到 **idf 的變化**，也把不是 tag 卻常常出現的字，從潛在詞彙中刪除，所以效能表現得比較好。可以考慮用 Ensemble 的方式進行投票，將兩者進行整合，達到更好的效果。

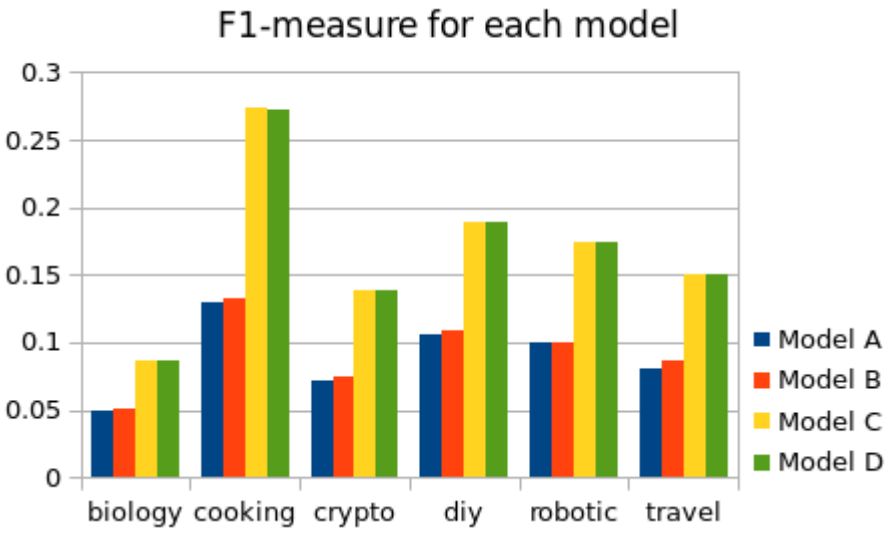


可以從直方圖中，清楚看到 Model C 和 Model D 都明顯優於 Model A 和 Model B，由此可知實際上的 **tag 的確幾乎都是名詞**的形式，而 **POS tag** 確實透過過濾掉不屬於名詞的詞彙提升不少準確率。

再來 Model B 都好於 Model A，顯示出在沒有 POS tag 的情況下，透過考慮到 **idf 的變化**，，效能表現得比較好。但在 Model C 和 Model D 中，idf 的效果就不明顯，甚至有些文章種類中效果還比較差，可能的原因是 POS tag 留下的名詞就已經有 idf 期望的效果在，甚至能找出 idf 所沒能留下的 tag，因此 idf 才會失去效用。

【註】：前述的 model A 和 model B 為了不讓過多的單詞被當作 tag，我們只取出現頻率前

600 的作為可能的 tag，超過的一律刪掉。實際上我們也實作了另一種方法是每個 id 只取前 N 常出現的詞彙當作 tag，在下表中以 model A(N) 表示。

| | model A | model A(3) | model A(4) | model A(5) |
|---|---|---|---|---|
| biology | 0.04901 | 0.04468 | 0.04758 | 0.04894 |
| cooking | 0.12958 | 0.11078 | 0.12723 | 0.13545 |
| crypto | 0.07165 | 0.10716 | 0.10480 | 0.10111 |
| diy | 0.10604 | 0.07682 | 0.08861 | 0.09619 |
| robotics | 0.09944 | 0.11604 | 0.12312 | 0.12487 |
| travel | 0.08002 | 0.04292 | 0.05632 | 0.06605 |

由上表可看出，除了 robotics 之外，大部份的文章種類套用固定 tag 數量並不會比較好，可能的主要原因是因為常見詞彙的前三名文章的 “類別 stop words”，也就是像 cooking 可能就會很常出現 cook 這個詞，但本身作為 tag 並沒有意義，而這些詞佔用了一個 tag 就表示減少其他真正可能 tag 被選上的機會，因此普遍成果沒有那麼好。因此我們仍採用是否屬於前 600 常見的詞的方式來選擇 tag。

2. Tag analysis

分析我們的模型跑出來的數量前二十名的 tag 與實際上數量前二十多的 tag 做比較，來判斷我們的模型是否能成功抓取到一些比較簡單的 tag。

(1.)Biology

Real tags(全部共 678 個 tags)

| | | | |
|---|---|---|---|
| 1. human-biology | 6. cell-biology | 11. physiology | 16. entomology |
| 2. genetics | 7. bioinformatics | 12. zoology | 17. homework |
| 3. evolution | 8. dna | 13. proteins | 18. molecular-genetics |
| 4. biochemistry | 9. neuroscience | 14. microbiology | 19. immunology |
| 5. molecular-biology | 10. botany | 15. species-identification | 20. bacteriology |

Our tags(全部共 8155 個 tags)

| | | | |
|---|---|---|---|
| 1. dna | 6. gene | 11. evolution | 16. plants |
| 2. cells | 7. difference | 12. plant | 17. bacteria |
| 3. cell | 8. protein | 13. body | 18. genes |
| 4. species | 9. human-body | 14. blood | 19. amino-acids |
| 5. human | 10. animals | 15. brain | 20. water |

(2.)Cooking

Real tags(全部共 736 個 tags)

| | | | |
|---|---|---|---|
| 1. baking | 6. chicken | 11. sauce | 16. cheese |
| 2. food-safety | 7. storage-method | 12. flavor | 17. oven |
| 3. substitutions | 8. eggs | 13. freezing | 18. chocolate |
| 4. equipment | 9. meat | 14. storage-lifetime | 19. coffee |
| 5. bread | 10. cake | 15. vegetables | 20. oil |

Our tags(全部共 5598 個 tags)

| | | | |
|---|---|---|---|
| 1. meat | 6. oil | 11.milk | 16. pan |
| 2. chicken | 7. difference | 12. substitute | 17. rice |
| 3. food | 8. water | 13. room-temperature | 18. recipe-calls |
| 4. bread | 9. cake | 14. chocolate | 19. olive-oil |
| 5. sauce | 10. recipe | 15. butter | 20. coffee |

(3.)Crypto

Real tags(全部共 392 個 tags):

| | | | |
|---|---|---|---|
| 1. encryption | 6. cryptanalysis | 11. protocol-design | 16. symmetric |
| 2. hash | 7. elliptic-curves | 12. random-number-generator | 17. homomorphic- encryption |
| 3. rsa | 8. signature | 13. diffie-hellman | 18. provable-security |
| 4. aes | 9. block-cipher | 14. keys | 19. hmac |
| 5. public-key | 10. algorithm-design | 15. authentication | 20. reference-request |

Our tags(全部共 4094 個 tags):

| | | | |
|---|---|---|---|
| 1. encryption | 6. security | 11.cipher | 16. key-exchangee |
| 2. hash-function | 7. secure | 12. attack | 17.algorithm |
| 3. public-key | 8. hash | 13. asymmetric-encryption- schemes | 18. hash-functions |
| 4.rsa | 9. key | 14. message | 19. cryptography |
| 5. private-key | 10. block-cipher | 15.data | 20. function |

(4.)DIY

Real tags(全部共 734 個 tags)

| | | | |
|---|---|---|---|
| 1. electrical | 6. bathroom | 11. concrete | 16.flooring |
| 2. plumbing | 7. repair | 12. insulation | 17. kitchens |
| 3. wiring | 8. water | 13. walls | 18. switch |
| 4. lighting | 9. wood | 14. doors | 19. shower |
| 5. hvac | 10. drywall | 15. basement | 20. heating |

Our tags(全部共 7314 個 tags)

| | | | |
|---|---|---|---|
| 1. water | 6. water-heat | 11. power | 16. circuit |
| 2. wall | 7. floor | 12. light-switch | 17. paint |
| 3. house | 8. wood | 13. living-room | 18. ceiling-fan |
| 4. wire | 9. ceiling | 14. toilet | 19. drywall |
| 5. door | 10. switch | 15. light-fixture | 20. furnace |

(5.)Robotic

Real tags(全部共 231 個 tags):

| | | | |
|---|---|---|---|
| 1. quadcopter | 6. sensors | 11. slam | 16. kinematics |
| 2. mobile-robot | 7. robotic-arm | 12. ros | 17. design |
| 3. arduino | 8. pid | 13. raspberry-pi | 18. kalman-filter |
| 4. control | 9. localization | 14. irobot-create | 19. computer-vision |
| 5. motor | 10. microcontroller | 15. wheeled-robot | 20. imu |

Our tags(全部共 2259 個 tags):

| | | | |
|---|---|---|---|
| 1. robot | 6. arduino | 11. create | 16. controller |
| 2.motor | 7. motors | 12. pid-controller | 17. inverse-kinematics |
| 3. control | 8. kalman-filter | 13. system | 18. camera |
| 4. quadcopter | 9. robotic-arm | 14. position | 19. robots |
| 5. sensor | 10. robotics | 15. data | 20. sensors |

(6.)Travel

Real tags(全部共 1645 個 tags):

| | | | |
|---|---|---|---|
| 1. visas | 6. customs-and-immigration | 11. luggage | 16. indian-citizens |
| 2. air-travel | 7. transit | 12. tickets | 17. europe |
| 3. usa | 8. trains | 13. legal | 18. india |
| 4. schengen | 9. passports | 14. budget | 19. online-resources |
| 5. uk | 10. public-transport | 15. canada | 20. germany |

Our tags(全部共 8037 個 tags):

| | | | |
|---|---|---|---|
| 1. visas | 6. schengen-visa | 11. public-transport | 16. days |
| 2. airport | 7. time | 12. ticket | 17. india |
| 3. travel | 8. transit-visa | 13. europe | 18. citizen |
| 4. passport | 9. country | 14. train | 19. flight |
| 5. flight | 10. tourist-visa | 15. luggage | 20. visa-application |

從以上表格中可以發現，實際 tags 與我們自己預測出來的 tags 最大的差異是在數量，都有五倍以上的差距。其原因可能是：第一，我們並沒有處理名詞**單複數**的問題(有沒有加"s")，例如：預測 robotics 的 tag 時，前 20 名同時出現了 **sensor** 與 **sensors**。第二，我們辨識出的 tag 其實意思重複性很高，像是 travel 類別中，其實有很多 **visa** 主題的 tag 都應該直接歸類成 visa 而不是當作一個新的 tag。第三，有些 tag 在實際的 tag 裡面沒有出現過，但是可能因為在文章中常常出現在相鄰的位置，經過 bigram 的計算，最後有機會變成候選的 tag。例如：預測 biolog 的 tag 時，前 20 名出現了 human-body，但是直接觀察所有實際的 tag 發現 human-body 根本沒有出現過。

3. Abbreviation replacement experiment

透過實驗，可以看出雖然不是每個領域都有 abbreviation 需要去替換，但只要有 abbreviation，就能確實地使預測進步。

| category | Model C with abbreviation replacement | Model C without abbreviation replacement |
|---|---|---|
| biology | 0.08600 | 0.08600 |
| cooking | 0.27287 | 0.27287 |
| crypto | 0.14506 | 0.13851 |
| diy | 0.18924 | 0.18899 |
| robotics | 0.17399 | 0.17399 |
| travel | 0.15018 | 0.15003 |

**★Conclusion**：

可以由上述的實驗，看出我們 model 的效能，使用 POS_tag，明顯對整體預測 tag 的效能有所提升。而分析了 tag 之後，我們的方法在面對字意重複的字，並無法有效的融合成目標 tag，可能還需要再用 clustering 的方式將字詞融合，以及用 Ensemble 進行多個 Model 的整合。

**★Reference**：


1.Transfer Learning on Stack Exchange Tags
https://www.kaggle.com/c/transfer-learning-on-stack-exchange-tags
2.TfidfVectorizer and CountVectorizer of sklearn
http://cikit-learn.org/stable/modules/classes.html#module-sklearn.feature_extraction.text
3.POS of nltk language toolkit
http:/www.nltk.org/book/ch05.html
4.BeautifulSoup4
https://www.crummy.com/software/BeautifulSoup/bs4/doc/
5.Mean F1-measure
http://nlp.stanford.edu/IR-book/html/htmledition/evaluation-of-clustering-1.html